

Reconocimiento de Actividades Humanas a partir de Sensores Inerciales de Smartphones

Propuesta de Proyecto de Machine Learning — Entrega 1

September 17, 2026

1. Contexto de aplicación

El reconocimiento de actividad humana (*Human Activity Recognition*, HAR) a partir de sensores inerciales embebidos en dispositivos móviles es un problema central en *ubiquitous computing*, salud digital y bienestar. A diferencia de los sistemas basados en cámaras, un smartphone portado por el usuario permite monitoreo continuo, de bajo costo y no intrusivo, sin requerir infraestructura externa ni comprometer la privacidad visual del usuario.

Las aplicaciones prácticas de este problema incluyen: (i) aplicaciones de *fitness* y salud que cuantifican minutos de actividad física diaria; (ii) sistemas de asistencia a adultos mayores que detectan caídas o inactividad prolongada; (iii) interfaces adaptativas que ajustan el comportamiento de una app según el contexto físico del usuario (caminando, sentado, en escaleras); y (iv) telemetría de salud para poblaciones clínicas (p. ej. pacientes con Parkinson, donde variantes de este problema se usan para detectar episodios de congelamiento de la marcha). En todos los casos, la propuesta de valor es transformar una señal cruda de acelerómetro/giroscopio —difícil de interpretar directamente— en una etiqueta semántica accionable (*caminando, sentado, subiendo escaleras*, etc.).

Este proyecto usa como caso de estudio el conjunto de datos público **UCI HAR Dataset** (*Human Activity Recognition Using Smartphones*), recolectado con un Samsung Galaxy S II portado en la cintura, y se apoya en el artículo de referencia de Murad & Pyun (2017) sobre arquitecturas de redes neuronales recurrentes profundas (DRNN) para esta tarea, el cual reporta resultados de desempeño directamente comparables sobre el mismo dataset.

2. Objetivo de machine learning

Se busca predecir la actividad física que realiza una persona (variable categórica de 6 clases) a partir de las señales inerciales de un smartphone (acelerómetro y giroscopio de 3 ejes) capturadas en ventanas de tiempo de 2.56 segundos.

Formalmente, es un problema de **clasificación multiclase supervisada**: dado un vector de entrada x (ya sea la señal cruda de 9 canales $\times$ 128 muestras temporales, o el vector de 561 características de dominio tiempo/frecuencia ya extraídas en el dataset), se busca aprender una función $f(x) \rightarrow y$, donde $y \in \{\text{WALKING, WALKING_UPSTAIRS, WALKING_DOWNSTAIRS, SITTING, STANDING, LAYING}\}$.

Como extensión natural (etapa posterior del proyecto), se explorará si el modelo puede generalizar a nuevos sujetos no vistos en entrenamiento (validación *subject-independent*), que es el escenario realista de despliegue en producción.

3. Dataset

3.1 Origen y tipo de datos

El dataset proviene de 30 voluntarios (19–48 años) que realizaron 6 actividades portando un smartphone en la cintura. El acelerómetro y giroscopio embebidos capturaron aceleración lineal y velocidad angular en 3 ejes a 50 Hz. Las señales se segmentaron en ventanas deslizantes de ancho fijo (128 lecturas, 2.56 s, con 50% de traslape). Para cada ventana se dispone de:

- **Señales inerciales crudas**: 9 canales de series de tiempo (aceleración total y aceleración corporal en X/Y/Z, velocidad angular en X/Y/Z), cada uno de 128 pasos temporales por ventana.

- **Vector de características (*engineered features*)**: 561 variables numéricas normalizadas en $[-1, 1]$, calculadas en dominio tiempo y frecuencia (media, desviación estándar, entropía, coeficientes FFT, etc.).
- **Etiqueta de actividad** (1 de 6 clases) e **identificador de sujeto** (1–30).

3.2 Tamaño

El dataset ya viene particionado por los autores originales en 70% de sujetos para entrenamiento y 30% para prueba (partición *subject-wise*, no aleatoria a nivel de ventana), lo que evita fuga de información entre sujetos.

Partición	# Sujetos	# Ventanas (ejemplos)	# Features
Entrenamiento	21	7,352	561
Prueba	9	2,947	561
Total	30	10,299	561

Table 1: Tamaño del dataset (71.4% train / 28.6% test).

En disco, el conjunto completo ocupa aproximadamente **270 MB** descomprimido (dominado por las señales inerciales crudas: 9 canales $\times$ 128 pasos $\times$ 10,299 ventanas $\approx$ 11.9 M valores flotantes por canal-partición) y **61 MB** comprimido (.zip). El vector de 561 características por sí solo ocupa $\approx$ 55 MB en texto plano.

3.3 Distribución de clases

Actividad	Train	%	Test	%
WALKING	1,226	16.7%	496	16.8%
WALKING_UPSTAIRS	1,073	14.6%	471	16.0%
WALKING_DOWNSTAIRS	986	13.4%	420	14.3%
SITTING	1,286	17.5%	491	16.7%
STANDING	1,374	18.7%	532	18.1%
LAYING	1,407	19.1%	537	18.2%

Table 2: Distribución de clases por partición. El dataset está razonablemente balanceado (ratio máx/mín $\approx$ 1.43), por lo que *accuracy* es una métrica interpretable sin ajustes adicionales, aunque igual se reportará F1 por clase.

4. Métricas de desempeño

4.1 Métricas de machine learning

- **Exactitud global (*accuracy*)**: proporción de ventanas correctamente clasificadas; métrica principal dado el balance razonable de clases.
- **Precisión y *recall* por clase**, y sus promedios macro: relevantes porque el costo de confundir actividades similares (p. ej. *sitting* vs. *standing*, o subir vs. bajar escaleras) no es simétrico.
- **F1-score (macro y ponderado)**: métrica de resumen robusta ante el leve desbalance de clases.
- **Matriz de confusión**: para diagnosticar pares de clases sistemáticamente confundidos (se anticipa confusión SITTING/STANDING, dado que ambas son posturas estáticas con perfil inercial similar).
- **Validación cruzada por sujeto (*leave-subjects-out*)** para estimar la capacidad de generalización a usuarios nuevos, más exigente que la partición aleatoria estándar.

4.2 Métricas de negocio

- **Latencia de inferencia por ventana (ms):** crítica si el modelo debe correr en tiempo real dentro del propio dispositivo móvil (*on-device inference*), condicionando el tamaño y complejidad del modelo elegible.
- **Consumo energético/computacional:** un modelo más pesado (p. ej. DRNN de varias capas) puede mejorar accuracy marginalmente a costa de batería, lo cual es relevante para una app de monitoreo continuo.
- **Tasa de falsos positivos en clases de riesgo:** en aplicaciones de salud (p. ej. detección de caídas o inactividad prolongada en adultos mayores), minimizar falsos negativos en la clase relevante es más importante que la exactitud global.
- **Robustez ante variabilidad de sujeto/dispositivo:** qué tanto se degrada el desempeño en usuarios y posiciones de sensor no vistos en entrenamiento, como *proxy* de qué tan bien generalizaría el modelo en producción real.

5. Referencias y resultados previos

1. Anguita, D.; Ghio, A.; Oneto, L.; Parra, X.; Reyes-Ortiz, J. L. (2013). *A Public Domain Dataset for Human Activity Recognition Using Smartphones*. 21st European Symposium on Artificial Neural Networks (ESANN), Bruges, Bélgica. — Publicación original del dataset; propone el modelo SVM multiclase usado como línea base de comparación en (2), con **96.0%** de exactitud sobre esta misma tarea.
2. Murad, A.; Pyun, J.-Y. (2017). *Deep Recurrent Neural Networks for Human Activity Recognition*. *Sensors*, 17(11), 2556. <https://doi.org/10.3390/s17112556>. — Referencia principal de este proyecto. Propone arquitecturas DRNN (LSTM unidireccional, bidireccional y en cascada) evaluadas en 5 datasets, incluyendo UCI-HAD. Para UCI-HAD, el modelo unidireccional de 4 capas alcanza **96.7% de exactitud global, 96.8% de precisión promedio, 96.7% de recall promedio y F1 = 0.96**, superando a SVM (96.0%), CNN (95.2%) y ELM secuencial (93.3%) reportados por los mismos autores como líneas base de comparación.
3. Jiang, W.; Yin, Z. (2015). *Human Activity Recognition using Wearable Sensors by Deep Convolutional Neural Networks*. Proc. 23rd ACM Int. Conf. on Multimedia. — Línea base de CNN usada como comparación en (2).
4. Chandan Kumar, R.; Bharadwaj, S. S.; Sumukha, B. N.; George, K. (2016). *Human activity recognition in cognitive environments using sequential ELM*. 2nd Int. Conf. on Cognitive Computing and Information Processing. — Línea base de *Extreme Learning Machine* secuencial.

Resumen de resultados previos sobre este mismo dataset (UCI-HAD):

Método (referencia)	Exactitud global
ELM secuencial [4]	93.3%
CNN [3]	95.2%
SVM [1]	96.0%
DRNN unidireccional (4 capas) [2] — estado del arte de referencia	96.7%

Table 3: Estos valores fijan el umbral de desempeño esperado para el modelo que se desarrollará en este proyecto: superar consistentemente a la línea base de ELM (93.3%) y acercarse o igualar el 96–97% reportado por SVM, CNN y DRNN sobre la misma tarea.